Programowanie równoległe i rozproszone

Politechnika Krakowska

Projekt

Temat

Porównanie czasów działania sieci neuronowych oraz głębokich sieci w środowiskach TensorFlow, PyTorch i Theano

Paweł Suchanicz,
Rafał Niemczyk

19 stycznia 2020

Spis treści

1 Wstęp **2**
1.1 Opis projektu . . . 2
1.2 Opis zbiorów danych . . . 2
1.2.1 MNIST . . . 2
1.2.2 CIFAR10 . . . 2
1.2.3 CIFAR100 . . . 3
1.2.4 Letter Recognition . . . 4
1.3 Opis użytych frameworków . . . 5
1.3.1 Keras . . . 5
1.3.2 Tensorflow . . . 5
1.3.3 PyTorch . . . 5
1.3.4 Theano . . . 6
1.4 Specyfikacja sprzętowa . . . 6

2 Wyniki **6**
2.1 Implementacja . . . 6
2.1.1 Wczytanie danych . . . 6
2.1.2 Architektura sieci . . . 7
2.1.3 Parametry uczenia . . . 13
2.1.4 Podział danych . . . 14
2.1.5 Walidacja krzyżowa . . . 14
2.2 Porównanie wyników - CPU . . . 14
2.2.1 Walidacja krzyżowa . . . 14
2.2.2 Podział danych 70/30 . . . 15
2.3 Porównanie wyników - GPU . . . 15
2.3.1 Walidacja krzyżowa . . . 15
2.3.2 Podział danych 70/30 . . . 15
2.4 Wykresy porównawcze według zbiorów . . . 17
2.5 Wnioski . . . 20

1 Wstęp

1.1 Opis projektu

Celem projektu było porównanie czasów działania sieci neuronowych oraz głębokich sieci neuronowych w środowiskach: TensorFlow, PyTorch oraz Theano. Czasy należało zmierzyć na CPU oraz GPU, jeśli była taka możliwość.

Pomiary czasów należało dokonać dla każdego z 4 zbiorów danych. Dlatego zbudowano 4 różne architektury sieci neuronowych. W każdym ze środowisk zbudowano te same architektury oraz zachowano te same parametry uczenia czy też funkcje aktywacji.

Dodatkowo należało dokonać eksperyment w 2 wariantach:

- Podział na zbiór uczący i testowy (70
- 10 krotna walidacja krzyżowa

Aby porównanie czasów było jak najbardziej obiektywne użyto domyślnego timera udostępnionego przez Python - timeit.

Aby uruchomić obliczenia sieci neuronowych na GPU należało użyć technologii CUDA. CUDA (Compute Unified Device Architecture) to architektura kart graficznych opracowana przez firmę Nvidia. Pozwala na wykorzystanie mocy obliczeniowej na kartach graficznych.

1.2 Opis zbiorów danych

1.2.1 MNIST

Jest to zestaw odręcznie napisanych cyfr (od 0 do 9), który powszechnie używany jest do szkolenia różnych systemów przetwarzania obrazu oraz w dziedzinie uczenia maszynowego. Baza danych MNIST zawiera 60 000 obrazów szkoleniowych i 10 000 obrazów testowych. Wielkość każdego obrazu to 28 x 28 pikseli w skali szarości.

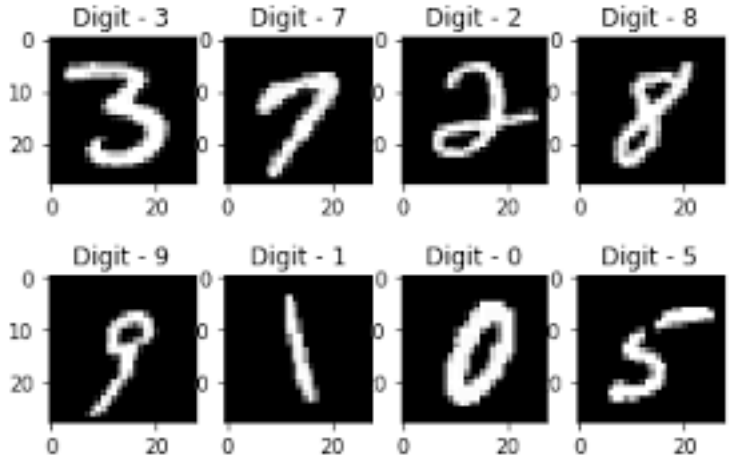

1.2.2 CIFAR10

Jest to zestaw zawierający 60 000 kolorowych obrazów o wielkości 32 x 32 pikseli. Obrazy przedstawiają jedną z 10 klas. Na poniższym obrazku znajdują sie klasy wraz z przykładowymi

obrazami. Każda klasa zawiera 6000 obrazów. Dane treningowe składają się z 50 000 obrazów, a testowe z 10 000, czyli w danych treningowych znajduję się 5 000 obrazów jednej klasy, a w testowe 1 000. Klasy całkowicie się wykluczają.

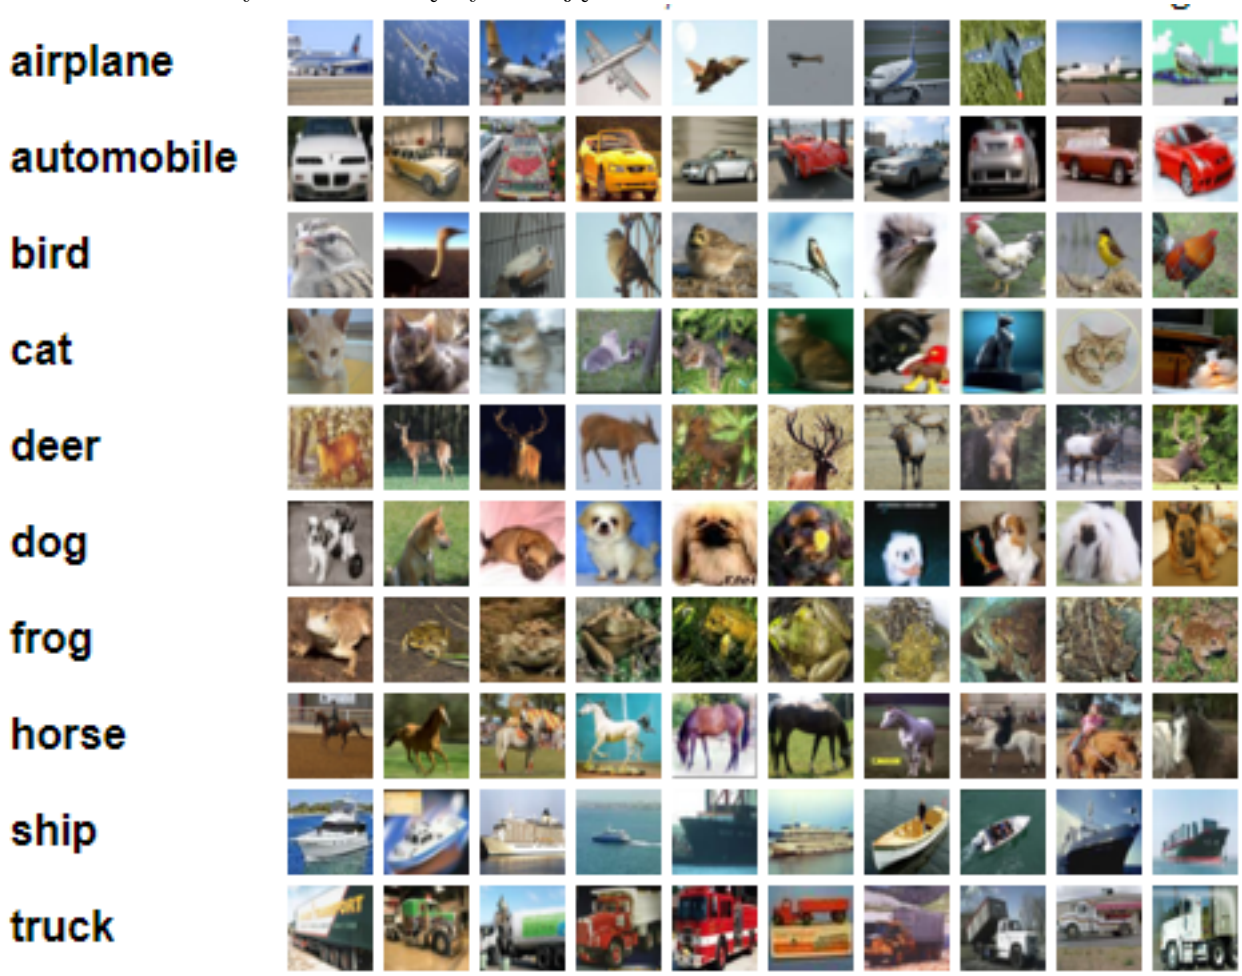

1.2.3 CIFAR100

Ten zestaw danych zawiera 60 000 kolorowych obrazów. Obrazy reprezentują 100 różnych klas, co oznacza, że na każdą klasę przypada 600 obrazów. Z każdej klasy wyodrębnionych zostaje 500 obrazów treningowych oraz 100 testowych. Każda z 100 klas jest przypisana do jednej z 20 superklas, czy też nadklas. Każdy obraz ma dwie etykiety. Jedną jako etykietę nadklasy i drugą jako własną. Poniżej znajduję się tabelami przedstawiająca nadklasy i klasy do nich należące.

Nazwa nadklasy	Nazwy klas zawartych w nadklasie
Ssaki wodne	bóbr, delfin, wydra, foka, wieloryb
Ryby	ryba akwariowa, rekin, pstrąg, płastugi, płaszczka
Kwiaty	storczyk, mak, róża, słonecznik, tulipan
Pojemniki na żywność	butelka, miska, puszka, kubek, talerz
Warzywa i owoce	jabłko, grzyb, pomarańcza, gruszka, papryka
Urządzenia elektryczne	zegar, klawiatura, lampa, telefon, telewizja
Meble domowe	łóżko, krzesło, kanapa, stół, szafa
Owady	pszczoła, chrząszcz, motyl, gąsienica, karaluch
Duże drapieżniki	niedźwiedź, lampart, lew, tygrys, wilk
Wszystkożerne i roślinożerne	wielbłąd, szympans, słoń, kangur, bydło
Średniej wielkości ssaki	lis, jeżozwierz, szop, skunks, opos
Bezkręgowce	krab, homar, ślimak, pająk, robak
Człowiek	niemowlę, chłopak, dziewczyna, mężczyzna, kobieta
Gady	krokodyl, dinozaur, jaszczurka, wąż, żółw
Małe ssaki	chomik, mysz, królik, wiewiórka, ryjówka
Drzewa	klon, dąb, palma, sosna, wierzba
Pojazdy 1	rower, autobus, motocykl, furgonetka, pociąg
Pojazdy 2	kosiarka, rakieta, tramwaj, czołg, ciągnik

1.2.4 Letter Recognition

Dane stworzone po to, aby móc na podstawie wyświetlanych pikseli zidentyfikować jedną z 26 wielkich liter alfabetu angielskiego. Obrazy znaków zostały oparte na 20 różnych czcionkach, a każda litera w tych 20 czcionkach została losowo zniekształcona, aby utworzyć plik zawierający 20 000 unikalnych cech. Każda litera składa się z 16 cech ją opisujących. Cechy, które tworzą poszczególną literę to:

- letter - wielka litera (od A do Z)
- x-box - pozioma pozycja x (liczba całkowita)
- y-box - pionowa pozycja y (liczba całkowita)
- width - szerokość (liczba całkowita)
- high - wysokość (liczba całkowita)
- onpix - całkowita liczba pikseli (liczba całkowita)
- x-bar - średnia liczba pikseli x (liczba całkowita)
- y-bar - średnia liczba pikseli y (liczba całkowita)
- x2bar - średnia wariancja x (liczba całkowita)
- y2bar - średnia wariancja y (liczba całkowita)
- xybar - średnia korelacja x y (liczba całkowita)
- x2ybr - średnia x * x * y (liczba całkowita)
- xy2br - średnia x * y * y (liczba całkowita)

- x-ege- średnia liczba krawędzi od lewej do prawej (liczba całkowita)
- xegvy - korelacja x krawędzi z y (liczba całkowita)
- y-ege- średnia liczba krawędzi od dołu do góry (liczba całkowita)
- yegvx - korelacja y krawędzi z x (liczba całkowita)

1.3 Opis użytych frameworków

1.3.1 Keras

Keras to biblioteka open-suorce do sieci neuronowych napisana w pythonie. zaprojektowana, aby umożliwić szybkie eksperymentowaie z głębokimi sieciami neuronowymi. Koncentruje się na byciu przyjazną dla użytkownika. W 2017 roku, zespół Google TensorFlow postanowił wesprzeć Keras w podstawowej bibliotece Tensorflow. Keras został mianowany jako przyjazny interfejs niż samodzielna platforma uczenia maszynowego. Oferuje bardziej intuicyjny zestaw narzędzi, które ułatwiają opracowywanie modeli głębokiego uczenia niezależnie od zastosowanego zaplecza obliczeniowego.

Keras był początkowo zawarty w temacie projektu, jednak po przeanalizowaniu i wgłebieniu się w temat frameworków do uczenia maszynowego w pythonie, zrezygnowano z tej opcji. Jak już wspomniano, biblioteka świetnie spisuje się do tworzenia architektury sieci neuronowych oraz do tworzenia całych modeli wraz z parametrami uczenia i funkcjami aktywacji. Jednak obliczenia wykonywane podczas treningu sieci, wykonywane domyślnie są za pomocą biblioteki TensorFlow. Aktualnie oprócz biblioteki obliczeniowej TensorFlow, są dostepne dwie inne biblioteki: Theano oraz CNTK.

1.3.2 Tensorflow

Tensorflow jest biblioteką open-source. Została napisana przez Google Brain Team w celu zastąpenia Theano. Wykorzystywana w uczeniu maszynowym i głębokich sieciach neuronowych. Została wydana 9 listopada 2015 roku. Biblioteka może do działania wykorzystywać zarówno karty graficzne, procesory jak i wyspecjalizowane mikroprocesory. Biblioteka składa się z kilku modułów. W jej najniższej warstwie znajduje się rozproszony silnik wykonawczy (ang. distributed execution engine), który w celu podniesienia wydajności został zaimplementowany w języku programowania C++. Nad nią znajdują się frontendy napisane w kilku językach programowania m.in. w Pythonie oraz C++. Powyżej umieszczona została warstwa API, która zapewnia prostszy interfejs dla powszechnie używanych warstw w modelach głębokiego uczenia. Na następną warstwę składają się wysokopoziomowe API, m.in. Keras oraz Estimator API, które ułatwiają tworzenie modeli i ich ocenę. Ponad tym znajdują się przygotowane przez twórców biblioteki gotowe do użycia modele.

Uważa się, że TensorFlow jest sybszy niz Theano. Jednak jest wolniejszy niz inne frameworki. Dodatkowo nie posiada zbyt dużej liczby wyszkolonych modeli.

1.3.3 PyTorch

Jest to open-source biblioteka do uczenia maszynowego, bazująca na bibliotece Torch. Używana do aplikacji jak przetwarzanie języka naturalnego. Opracowana głównie przez Facebook AI Research lab. Oprócz interfejsu pythona, posiada interfejs C++. Na PyTorch zbudowanych

jest wiele elementów oprogramowania do głębokiego uczenia, jak Uber Pyro. Zapewnia dwie funkcje wysokiego poziomu:

- obliczenia tensorowe z silnym przyśpieszeniem za pośrednictwem procesorów graficznych GPU
- głębokie sieci neuronowe zbudowane na systemie autodiff

Do plusów biblioteki można zaliczyć np: wiele modułów, które można łatwo połączyć; łatwe pisanie własnych typów warstw i uruchamianie na GPU, wiele wstępnie przeszkolonych modeli. Minusami tej biblioteki są: pisanie własnego kodu treningowego, brak wsparcia.

1.3.4 Theano

Jest to biblioteka i kompilator optymalizujący wyrażenia matematyczne. W Theano obliczenia są wyrażane przy użyciu składni w stylu NumPy i kompilowane w celu wydajnego działania na architekturze CPU lub GPU. Projekt typu open-source, opracowany przede wszystkim przez Montreal Institute for Learning na Uniwerstytecie w Montrealu. W dniu 28 września 2017 roku, Yoshua Bengio ogłosił: "Główny rozwój zostanie zakończony po wydaniu wersji 1.0, z powodu konkurencyjnych ofert silnych graczy przemysłowych. Wersja 1.0.0 została wydana 15 listopada 2017r. Na Theano zbudowano biblioteki głębokiego uczenia jak Keras, Lagane i Blocks.

1.4 Specyfikacja sprzętowa

Przy pomiarach szybkości wykonywania algorytmów wykorzystany był sprzęt w konfiguracji - do implementacji z wykorzystaniem CUDA.
Specyfikacja sprzętu:

- Procesor: Intel Core i7-4712MQ 4 x 2.30GHz
- Ram: 8GB DDR3
- System: Windows 10
- GPU: NVIDIA GeForce 840N

2 Wyniki

2.1 Implementacja

W projekcie należało użyć trzech frameworków: TensorFlow, PyTorch oraz Theano. Dwa z nich, TensorFlow oraz Theano, można użyć jako backend do biblioteki Keras. Dzięki czemu dla tych dwóch frameworków stworzono cały model uczenia używając dokładnie tych samych funkcji dostępnych dzięki Keras.

2.1.1 Wczytanie danych

Trzy z 4 zbiorów danych zawarte są w paczkach danych udostępnionych przez Keras. Należało jedynie poprawnie wywołać odpowiednią funkcję. Podobnie sytuacja wyglądała w PyTorch, gdzie zbiory były dostępne i również należało wykonać poszczególną funkcję.

Aby wczytać zbiór LetterRecognition należało użyć funkcji read-csv dostępnej w paczce Pandas.

Dane nie wymagały zbyt dużej obróbki, ponieważ nie brakowało żadnych wartości oraz były zapisane w postaci numerycznej. Podczas wczytania danych poprzez funkcję udostępnioną przez Keras, dane były domyślnie dzielone na treningowe i testowe. Jednak proporcje tych danych nie spełniały wymagań projektowych. Dlatego łączono dane i dopiero w następnym kroku dzielono je na odpowiednie proporcje lub używano do walidacji krzyżowej.

2.1.2 Architektura sieci

Stworzenie architektury sieci w bibliotece Keras polega głównie na funkcjach udostępnianych przez bibliotekę. Jest to bardzo proste zajęcie, należy tylko odpowiednie dodawać kolejne warstwy sieci do modelu.

W przypadku PyTorch sytuacja wygląda bardzo podobnie. Należy odpowiednio ułożyć warstwy sieci. Główne różnice można zauważyć w nazewnictwie.

Poniżej znajdują się utworzone architektury sieci dla każdego ze zbiorów danych.

- MNIST

Layer (type)	Output Shape	Param #
conv2d_2 (Conv2D)	multiple	320
conv2d_3 (Conv2D)	multiple	18496
max_pooling2d_1 (MaxPooling2	multiple	0
dropout_2 (Dropout)	multiple	0
dense_2 (Dense)	multiple	1179776
flatten_1 (Flatten)	multiple	0
dropout_3 (Dropout)	multiple	0
dense_3 (Dense)	multiple	1290

Total params: 1,199,882
Trainable params: 1,199,882
Non-trainable params: 0

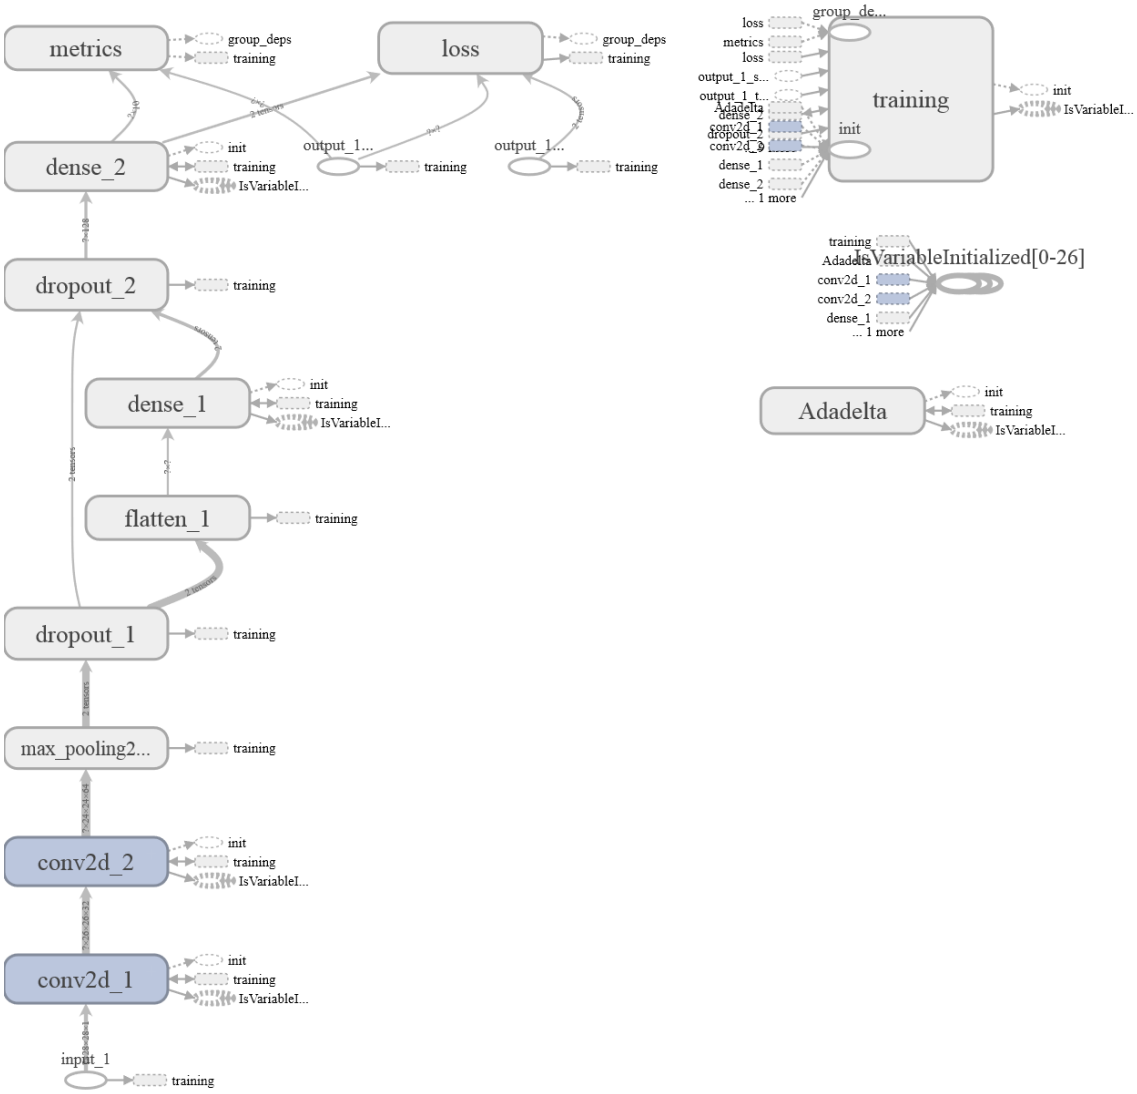
metrics
group_deps
training
loss
group_deps
training
dense_2
init
training
IsVariableI...
output_1...
training
output_1...
training
dropout_2
training
dense_1
init
training
IsVariableI...
flatten_1
training
dropout_1
training
max_pooling2...
training
conv2d_2
init
training
IsVariableI...
conv2d_1
init
training
IsVariableI...
input_1
training
group_de...
loss
metrics
loss
output_1_s...
output_1_t...
dense_2
conv2d_1
dropout_2
dense_1
dense_2
... 1 more
training
init
IsVariableI...
training
Adadelta
conv2d_1
conv2d_2
dense_1
... 1 more
IsVariableInitialized[0-26]
Adadelta
init
training
IsVariableI...

- CIFAR10

```
Model: "cifar10_model"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
conv2d (Conv2D)              multiple                  896
_________________________________________________________________
conv2d_1 (Conv2D)            multiple                  9248
_________________________________________________________________
max_pooling2d (MaxPooling2D) multiple                  0
_________________________________________________________________
dropout (Dropout)            multiple                  0
_________________________________________________________________
conv2d_2 (Conv2D)            multiple                  18496
_________________________________________________________________
conv2d_3 (Conv2D)            multiple                  36928
_________________________________________________________________
max_pooling2d_1 (MaxPooling2 multiple                  0
_________________________________________________________________
dropout_1 (Dropout)          multiple                  0
_________________________________________________________________
flatten (Flatten)            multiple                  0
_________________________________________________________________
dense (Dense)                multiple                  1180160
_________________________________________________________________
dropout_2 (Dropout)          multiple                  0
_________________________________________________________________
dense_1 (Dense)              multiple                  5130
=================================================================
Total params: 1,250,858
Trainable params: 1,250,858
Non-trainable params: 0
_________________________________________________________________
```

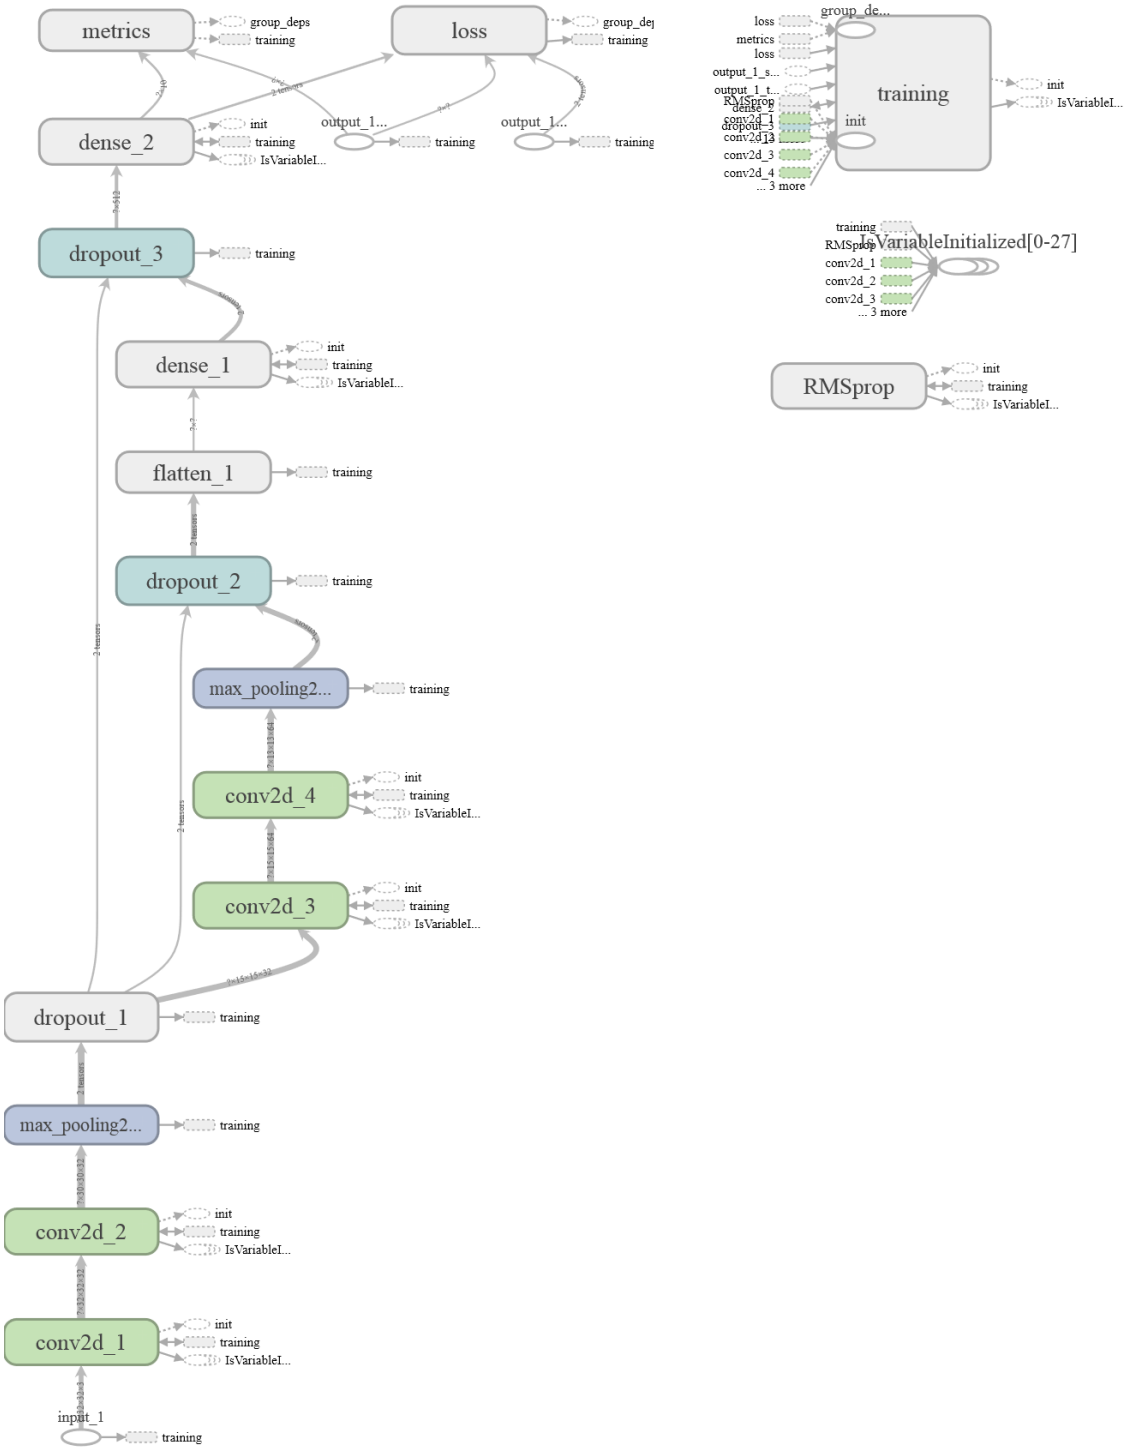
metrics
group_deps
training
loss
group_dep
training
dense_2
init
training
IsVariableI...
output_1...
training
output_1...
training
dropout_3
training
dense_1
init
training
IsVariableI...
flatten_1
training
dropout_2
training
max_pooling2...
training
conv2d_4
init
training
IsVariableI...
conv2d_3
init
training
IsVariableI...
dropout_1
training
max_pooling2...
training
conv2d_2
init
training
IsVariableI...
conv2d_1
init
training
IsVariableI...
input_1
training
group_de...
loss
metrics
loss
output_1_s...
output_1_t...
RMSprop
dense_2
conv2d_1
dropout_3
conv2d_2
conv2d_3
conv2d_4
... 3 more
training
init
IsVariableI...
training
RMSprop
conv2d_1
conv2d_2
conv2d_3
... 3 more
IsVariableInitialized[0-27]
RMSprop
init
training
IsVariableI...

- CIFAR100

```
Model: "cifar100_model"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
conv2d (Conv2D)              multiple                  896
_________________________________________________________________
conv2d_1 (Conv2D)            multiple                  9248
_________________________________________________________________
max_pooling2d (MaxPooling2D) multiple                  0
_________________________________________________________________
dropout (Dropout)            multiple                  0
_________________________________________________________________
conv2d_2 (Conv2D)            multiple                  18496
_________________________________________________________________
conv2d_3 (Conv2D)            multiple                  36928
_________________________________________________________________
max_pooling2d_1 (MaxPooling2 multiple                  0
_________________________________________________________________
dropout_1 (Dropout)          multiple                  0
_________________________________________________________________
flatten (Flatten)            multiple                  0
_________________________________________________________________
dense (Dense)                multiple                  1180160
_________________________________________________________________
dropout_2 (Dropout)          multiple                  0
_________________________________________________________________
dense_1 (Dense)              multiple                  51300
=================================================================
Total params: 1,297,028
Trainable params: 1,297,028
Non-trainable params: 0
```

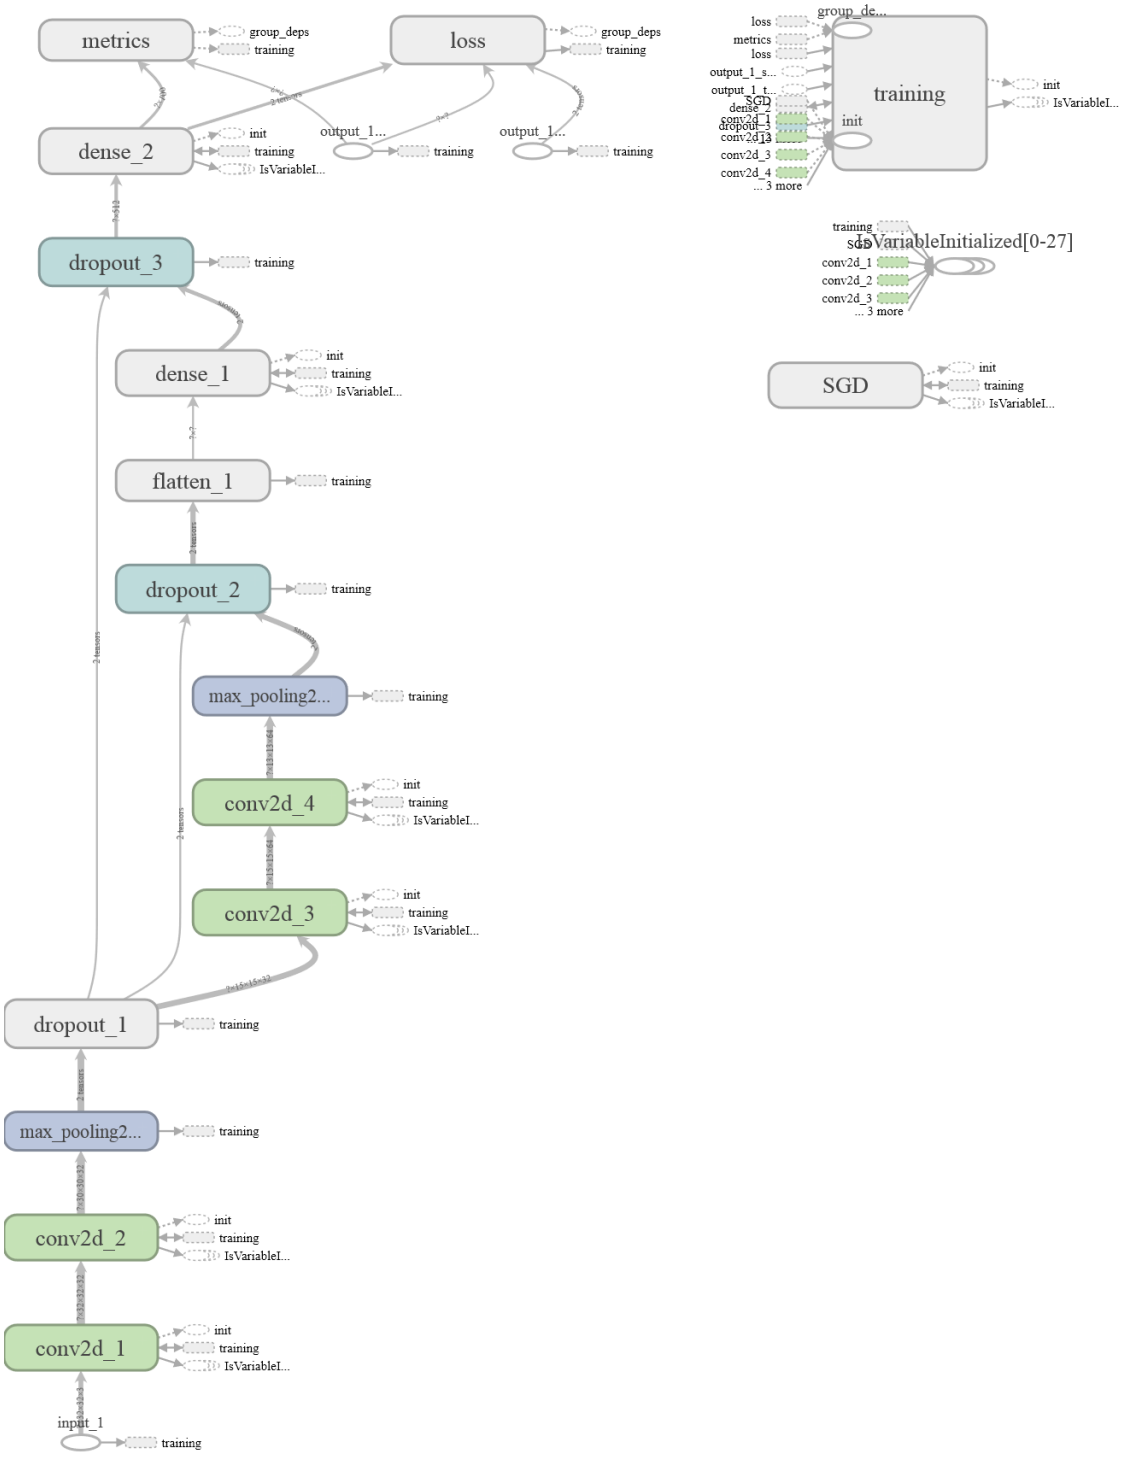
metrics
group_deps
training
loss
group_deps
training
dense_2
init
training
IsVariableI...
output_1...
training
output_1...
training
dropout_3
training
dense_1
init
training
IsVariableI...
flatten_1
training
dropout_2
training
max_pooling2...
training
conv2d_4
init
training
IsVariableI...
conv2d_3
init
training
IsVariableI...
dropout_1
training
max_pooling2...
training
conv2d_2
init
training
IsVariableI...
conv2d_1
init
training
IsVariableI...
input_1
training
group_de...
loss
metrics
loss
output_1_s...
output_1_t...
SGD
dense_2
conv2d_1
dropout_3
conv2d_2
conv2d_3
conv2d_4
... 3 more
training
init
IsVariableI...
training
SGD
conv2d_1
conv2d_2
conv2d_3
... 3 more
IsVariableInitialized[0-27]
SGD
init
training
IsVariableI...

- LetterRecognition

```
Model: "letter_recignition_model"
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
dense (Dense)                multiple                  850
_________________________________________________________________
dropout (Dropout)            multiple                  0
_________________________________________________________________
dense_1 (Dense)              multiple                  1122
_________________________________________________________________
dropout_1 (Dropout)          multiple                  0
_________________________________________________________________
dense_2 (Dense)              multiple                  598
=================================================================
Total params: 2,570
Trainable params: 2,570
Non-trainable params: 0
_________________________________________________________________
```

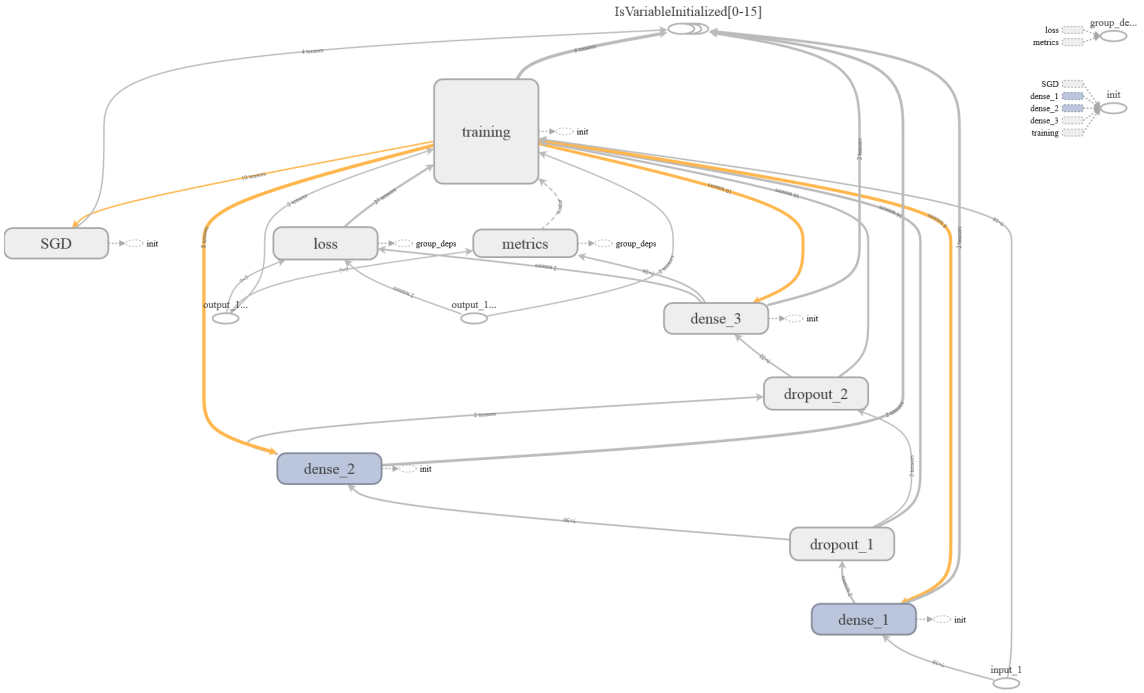

2.1.3 Parametry uczenia

Dla każdej architektury dobrane inne parametry uczenia, co wyszczególniono poniżej:

- MNIST:
  - funkcja błędu - categorical-crossentropy
  - optymalizator - Adadelta()
  - batch-size = 128

  - liczba epok = 12

- CIFAR10:
  - funkcja błędu - categorical-crossentropy
  - optymalizator - RMSprop(learning-rate=0.0001, decay=1e-6)
  - batch-size = 128
  - liczba epok = 12

- CIFAR100:
  - funkcja błędu - categorical-crossentropy
  - optymalizator - SGD(lr=0.01, decay=1e-6, momentum=0.9, nesterov=True)
  - batch-size = 128
  - liczba epok = 12

- LetterRecognition:
  - funkcja błędu - categorical-crossentropy
  - optymalizator - SGD(lr=0.001, decay=1e-7, momentum=0.)
  - batch-size = 128
  - liczba epok = 300

Aby zainicjalizować wagi w Keras należy użyć metody compile, natomiast w PyTorch należy przekazać funkcję modyfikującą wagi. Tworzenie optymalizatorów jest bardzo podobne w obu frameworkach.

2.1.4 Podział danych

Wykonując zadanie zawarte w poleceniu, tzn aby podzielić dane na testowe i treningowe w proporcji 70%/30% użyto funkcji train-test-split z pakietu sklearn.

2.1.5 Walidacja krzyżowa

Walidacja krzyżowa jest metodą statystyczną, polegająca na podziale próby statystycznej na podzbiory, a następnie przeprowadzaniu wszelkich analiz na niektórych z nich (zbiór uczący), podczas gdy pozostałe służą do potwierdzenia wiarygodności jej wyników (zbiór testowy). K-Krotna walidacja to metoda w której oryginalna próba jest dzielona na K podzbiorów. Następnie kolejno każdy z nich bierze się jako zbiór testowy, a pozostałe razem jako zbiór uczący i wykonuje analizę. Analiza jest więc wykonywana K razy. K rezultatów jest następnie uśrednianych (lub łączonych w inny sposób) w celu uzyskania jednego wyniku. Aby skorzystać z walidacji krzyżowej użyto funkcji KFold z pakietu sklearn.

2.2 Porównanie wyników - CPU

2.2.1 Walidacja krzyżowa

Porównanie wyników, gdy uczenie sieci uruchomiono na CPU i wykorzystano walidację krzyżową.

Czas wykonania

	TensorFlow	Theano	PyTorch
MNIST	12089.98s	12405.71s	23848.42s
CIFAR10	15902.45s	19150.98s	27867.25s
CIFAR100	17127.30s	457762.47s	32609.92s
LetterRec	1551.61s	1071.60s	2019.43s

Test accuracy

	TensorFlow	Theano	PyTorch
MNIST	82.56%	83.86%	98.97%
CIFAR10	61.72%	62.95%	62.70%
CIFAR100	39.52%	46.13%	43.92%
LetterRec	69.25%	67.60%	66.55%

2.2.2 Podział danych 70/30

Porównanie wyników, gdy uczenie sieci uruchomiono na CPU i wykorzystano podział 70/30.

Czas wykonania

	TensorFlow	Theano	PyTorch
MNIST	1005.69s	1928.22s	1281.81s
CIFAR10	1480.35s	3112.23s	1524.95s
CIFAR100	1551.61s	74422.8454s	1890.53s
LetterRec	90.876s	108.85s	154.82s

Test accuracy

	TensorFlow	Theano	PyTorch
MNIST	81.26%	98.96%	98.61%
CIFAR10	57.63%	57.27%	48.75%
CIFAR100	39.54%	44.21%	36.34%
LetterRec	3.2%	3.68%	48.82%

2.3 Porównanie wyników - GPU

2.3.1 Walidacja krzyżowa

Porównanie wyników, gdy uczenie sieci uruchomiono na GPU i wykorzystano walidację krzyżową.

Czas wykonania

	TensorFlow	Theano	PyTorch
MNIST	3623.60s	7587.83s	4026.90s
CIFAR10	4558.62s	9226.08s	3876.99s
CIFAR100	4264.93s	10257.84s	3907.12s
LetterRec	1905.68s	1451.61s	5090.07s

Test accuracy

	TensorFlow	Theano	PyTorch
MNIST	83.34%	98.94%	99.08%
CIFAR10	63.10%	62.60%	62.53%
CIFAR100	37.09%	36.43%	44.41%
LetterRec	67.46 %	72.25	50.15%

2.3.2 Podział danych 70/30

Porównanie wyników, gdy uczenie sieci uruchomiono na GPU i wykorzystano podział 70/30.

Czas wykonania

	TensorFlow	Theano	PyTorch
MNIST	318.34s	654.99s	293.51s
CIFAR10	407.71s	779.47s	297.83s
CIFAR100	377.30s	876.40s	298.36s
LetterRec	182.15s	141.96s	288.27s

Test accuracy

	TensorFlow	Theano	PyTorch
MNIST	81,42%	98.98%	98.44%
CIFAR10	59,86%	62.60%	49.63%
CIFAR100	38,69%	36.43%	33.16%
LetterRec	3,9%	3.28%	48.40%

2.4 Wykresy porównawcze według zbiorów

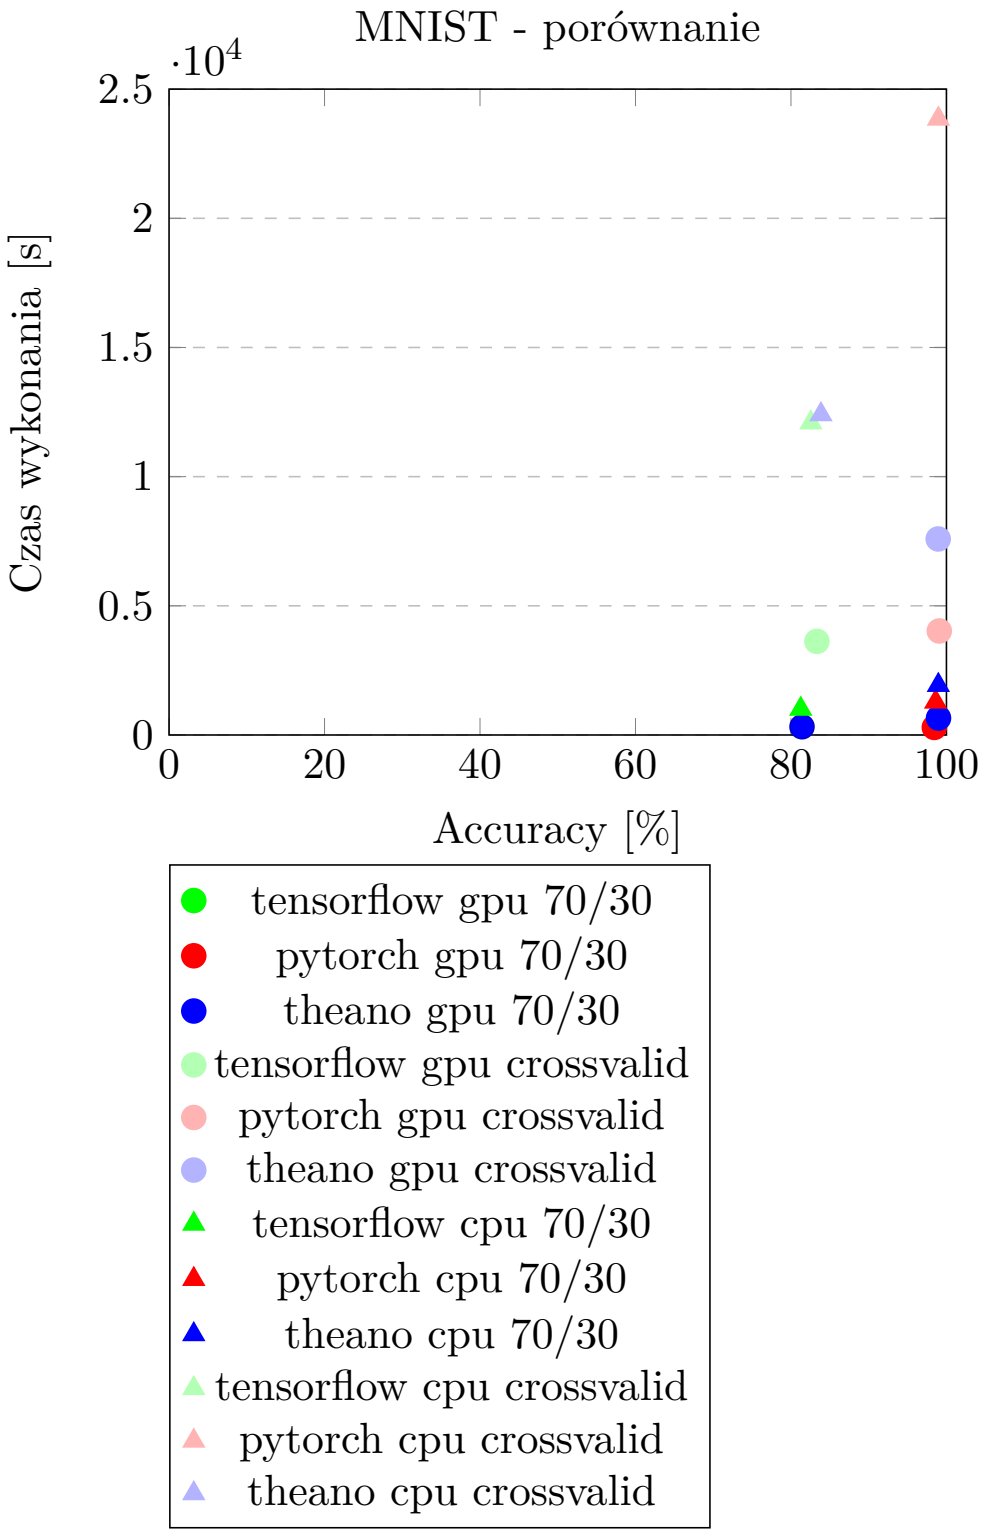

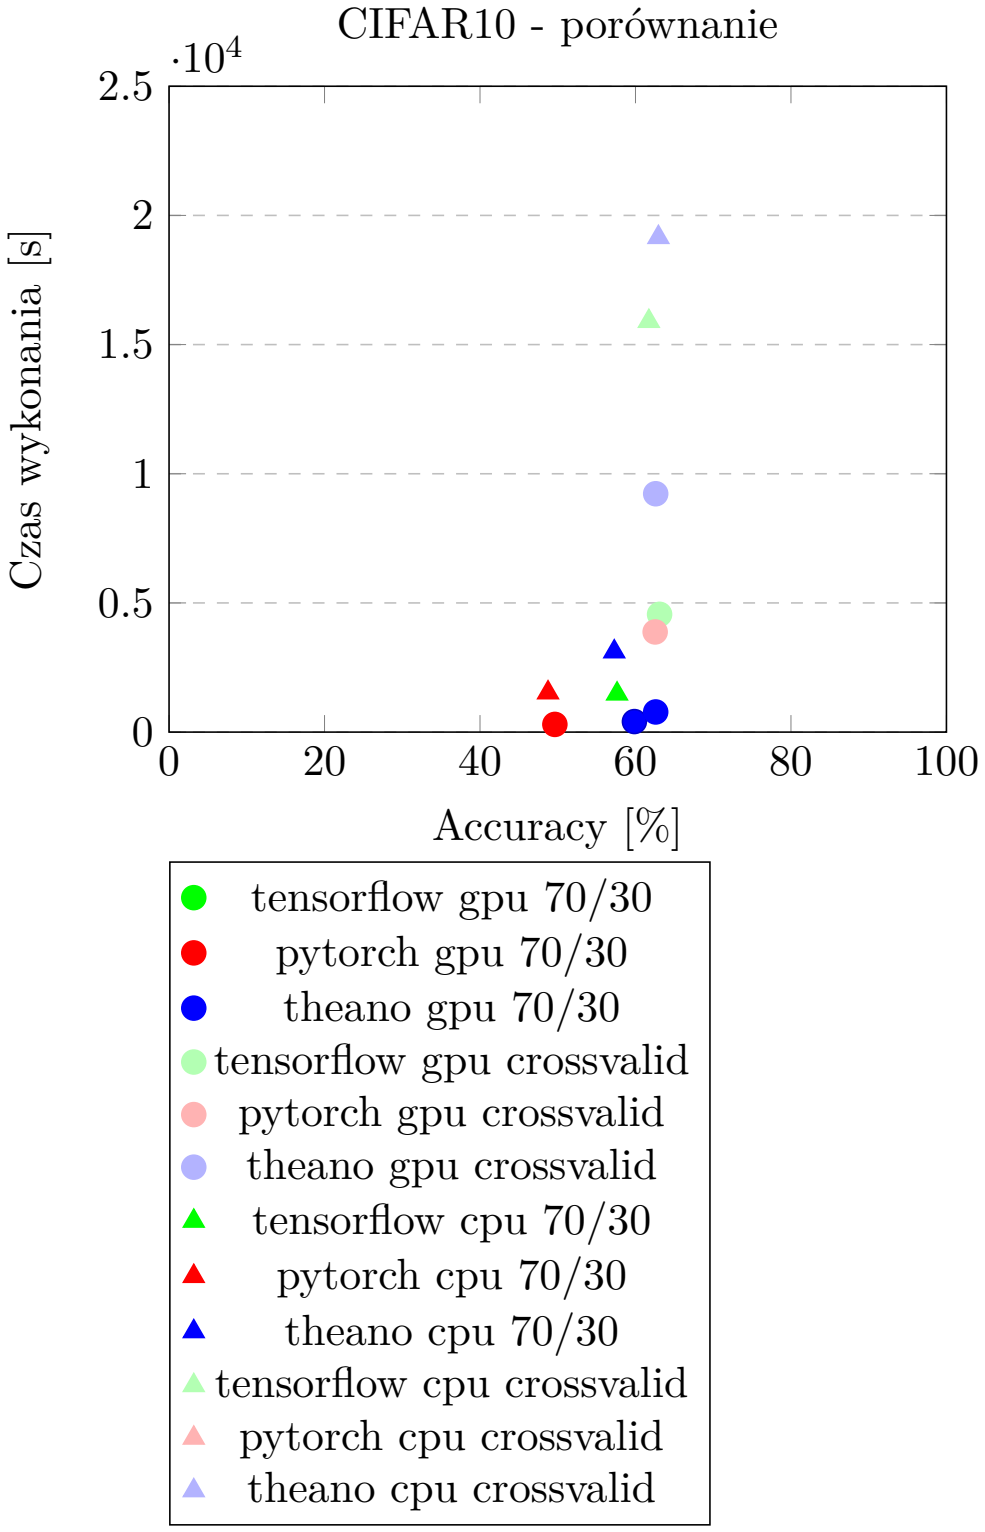
CIFAR10 - porównanie
$\cdot 10^4$
2.5
2
1.5
1
0.5
0
Czas wykonania [s]
0
20
40
60
80
100
Accuracy [%]
tensorflow gpu 70/30
pytorch gpu 70/30
theano gpu 70/30
tensorflow gpu crossvalid
pytorch gpu crossvalid
theano gpu crossvalid
tensorflow cpu 70/30
pytorch cpu 70/30
theano cpu 70/30
tensorflow cpu crossvalid
pytorch cpu crossvalid
theano cpu crossvalid

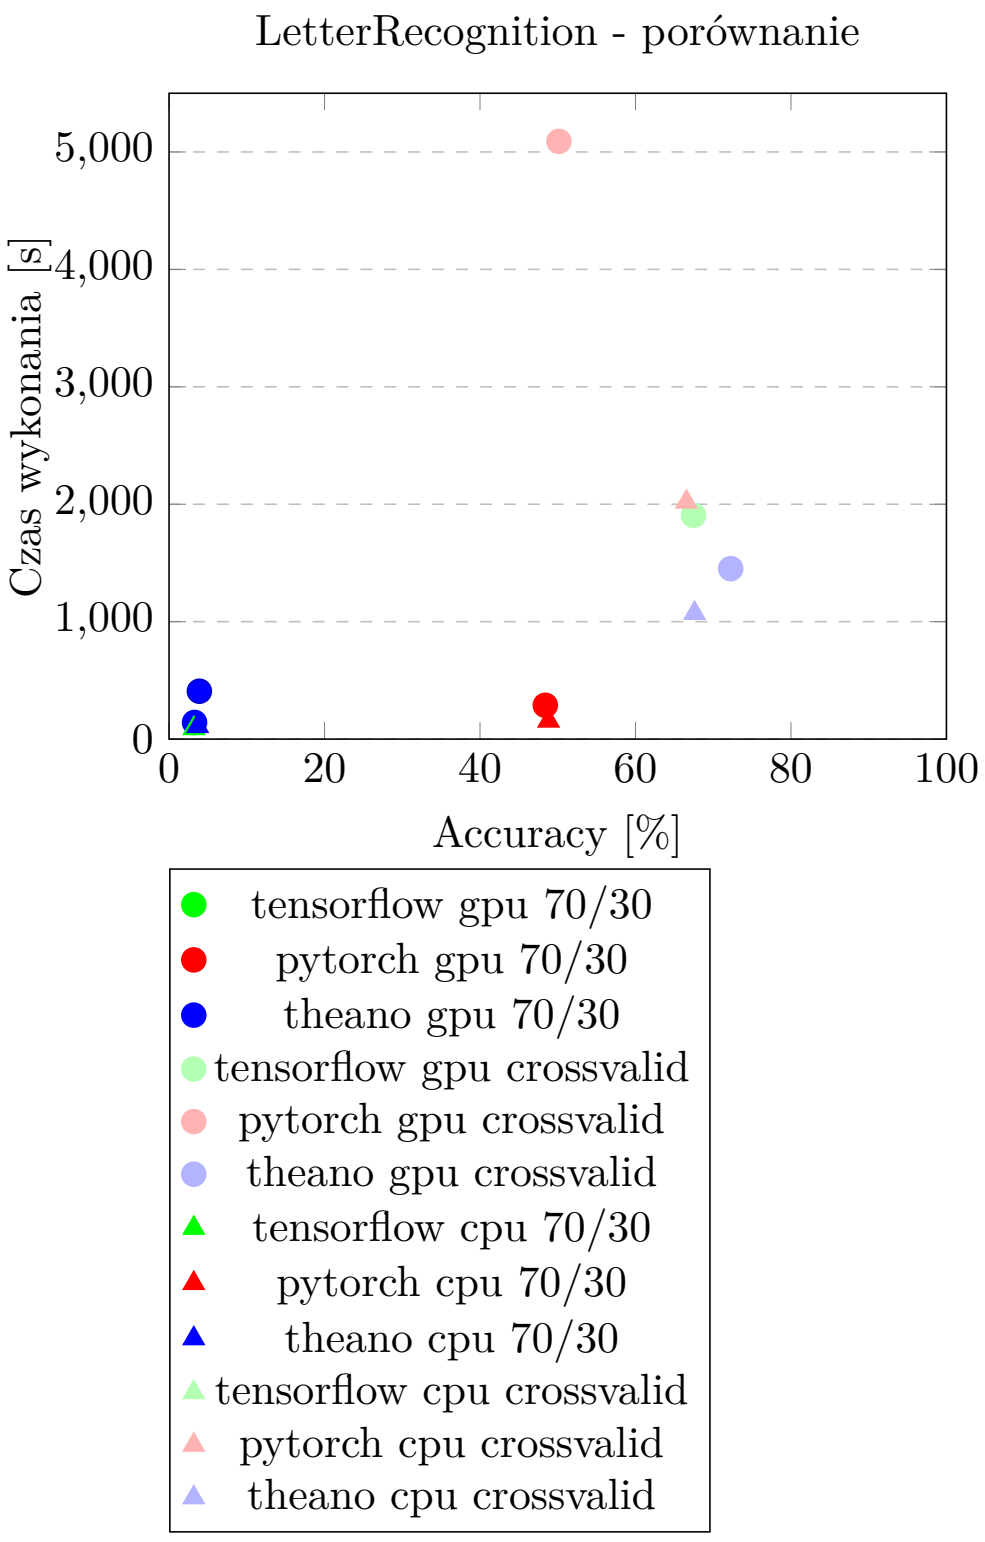
LetterRecognition - porównanie
Czas wykonania [s]
5,000
4,000
3,000
2,000
1,000
0
0
20
40
60
80
100
Accuracy [%]
tensorflow gpu 70/30
pytorch gpu 70/30
theano gpu 70/30
tensorflow gpu crossvalid
pytorch gpu crossvalid
theano gpu crossvalid
tensorflow cpu 70/30
pytorch cpu 70/30
theano cpu 70/30
tensorflow cpu crossvalid
pytorch cpu crossvalid
theano cpu crossvalid

2.5 Wnioski

Z powyższych porównań przedstawionych w tabelach i na wykresach można wyciągnąć następujące wnioski:

- Sieci neuronowe konwolucyjne, które były wykorzystane do klasyfikacji obrazów (tj. dla zbiorów MNIST, CIFAR10, CIFAR100) zdecydowanie szybciej działają jeżeli do obliczeń wykorzystywany jest GPU.
- Dla sieci wykorzystanej dla zbioru Letter-Recognition lepiej użyć CPU do obliczeń. Użycie GPU zwiększyło znacznie długość uczenia sieci. Efekt był najbardziej widoczny w przypadku użycia bibliotek pytorch i tensorflow.
- 10-krotna walidacja krzyżowa zgodnie z oczekiwaniami zwiększała czas uczenia około 10-krotnie oraz sprawiała że wynik accuracy był mniej obciążony błedami związanymi z przeuczeniem sieci. Walidacja krzyżowa zazwyczaj nie zwiększa dokładności, ale dla zbioru Letter-Recognition zauważyliśmy znaczną poprawę w wynikach po jej użyciu (z około 3 do około 70 procent).
- Biblioteka Theano okazała się najwolniejsza dla sieci konwolucyjnych, natomiast najszybciej ze wszystkich testowanych bibliotek poradziła sobie z siecią dla zbioru Letter-Recogniton.
- Implementacje oraz domyślne parametry niektórych funkcji, optymalizatorów, inicjaliztorów wag, klas do czytania danych itp. różnią się dla każdej biblioteki. Stąd wynikają różnice w otrzymywanych wynikach Accuracy dla każdej z bibliotek.